

```
In [82]: import pandas as pd
import re
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity
import numpy as np
import ipywidgets as widgets
from IPython.display import display, Markdown, clear_output
import nltk
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
```

Lettura del data set

```
In [83]: data_set = pd.read_csv("C:/Users/massi/OneDrive/Desktop/Sistema di raccomandazione notizie con Python/News.csv")
```

```
In [84]: data_set.head()
```

	ID	News Category	Title	Summary	Unnamed: 4	Unnamed: 5	Unnamed: 6	Unnamed: 7
0	N88753	lifestyle	The Brands Queen Elizabeth, Prince Charles, an...	Shop the notebooks, jackets, and more that the...	NaN	NaN	NaN	NaN
1	N45436	news	Walmart Slashes Prices on Last-Generation iPads	Apple's new iPad releases bring big deals on l...	NaN	NaN	NaN	NaN
2	N23144	health	50 Worst Habits For Belly Fat	These seemingly harmless habits are holding yo...	NaN	NaN	NaN	NaN
3	N86255	health	Dispose of unwanted prescription drugs during ...	NaN	NaN	NaN	NaN	NaN
4	N93187	news	The Cost of Trump's Aid Freeze in the Trenches...	Lt. Ivan Molchanets peeked over a parapet of s...	NaN	NaN	NaN	NaN

Elimino le colonne: 'ID','Unnamed: 4','Unnamed: 5','Unnamed: 6','Unnamed: 7'

```
In [85]: data_set = data_set.drop(columns=['ID','Unnamed: 4', 'Unnamed: 5',
'Unnamed: 6', 'Unnamed: 7'])
```

Dimensione del data set

```
In [86]: data_set.shape
```

```
Out[86]: (17357, 3)
```

Struttura del data set

```
In [87]: data_set.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 17357 entries, 0 to 17356
Data columns (total 3 columns):
#   Column      Non-Null Count  Dtype
---  -
0   News Category  17357 non-null  object
1   Title         17357 non-null  object
2   Summary       16577 non-null  object
dtypes: object(3)
memory usage: 406.9+ KB
```

Eliminiamo i valori mancanti (NA) presenti nel summary

```
In [88]: data_set = data_set.dropna()
```

Riconrollo la dimensione del data set

```
In [89]: data_set.shape
```

```
Out[89]: (16577, 3)
```

Il data set si presenta nel seguente modo

```
In [90]: data_set.head()
```

	News Category	Title	Summary
0	lifestyle	The Brands Queen Elizabeth, Prince Charles, an...	Shop the notebooks, jackets, and more that the...
1	news	Walmart Slashes Prices on Last-Generation iPads	Apple's new iPad releases bring big deals on l...
2	health	50 Worst Habits For Belly Fat	These seemingly harmless habits are holding yo...
4	news	The Cost of Trump's Aid Freeze in the Trenches...	Lt. Ivan Molchanets peeked over a parapet of s...
5	health	I Was An NBA Wife. Here's How It Affected My M...	I felt like I was a fraud, and being an NBA wi...

```
In [91]: nltk.download('stopwords')
nltk.download('wordnet')
nltk.download('omw-1.4')

stop_words = set(stopwords.words('english'))
lemmatizer = WordNetLemmatizer()

# Funzione di pulizia testo
def clean_text(text):
    text = text.lower()
    text = re.sub(r'\W+', ' ', text)
    text = re.sub(r'\d+', '', text)
    tokens = text.split()
    tokens = [lemmatizer.lemmatize(w) for w in tokens if w not in stop_words]
    return ' '.join(tokens)

# Applico la pulizia
data_set["cleaned_text"] = (data_set["Title"]).apply(clean_text)

# Calcolo TF-IDF sulla colonna pulita

vectorizer = TfidfVectorizer(ngram_range=(1, 2))
tfidf = vectorizer.fit_transform(data_set["cleaned_text"])
```

```
[nltk_data] Downloading package stopwords to
[nltk_data] C:\Users\massi\AppData\Roaming\nltk_data...
[nltk_data] Package stopwords is already up-to-date!
[nltk_data] Downloading package wordnet to
[nltk_data] C:\Users\massi\AppData\Roaming\nltk_data...
[nltk_data] Package wordnet is already up-to-date!
[nltk_data] Downloading package omw-1.4 to
[nltk_data] C:\Users\massi\AppData\Roaming\nltk_data...
[nltk_data] Package omw-1.4 is already up-to-date!
```

Con ngram_range=(1,2) prendiamo in considerazione singole parole e coppie di parole consecutive

Esempio -> Titolo: "trump wins election"

ngram_range = 1: ['trump', 'wins', 'election']

ngram_range = 2: ['trump wins', 'wins election']

tfidf è una matrice sparsa di dimensioni (n_titoli, n_caratteristiche) in cui ogni riga rappresenta un titolo e ogni colonna rappresenta un unigram o bigram.

Il contenuto è il valore TF-IDF di quel termine nel titolo.

Definiamo la funziona search. Dato il titolo di una news, applica vectorizer.transform che converte il testo title in un vettore numerico che rappresenta l'importanza delle parole nel titolo.

Successivamente calcoliamo la similarità del coseno tra il vettore del titolo (query_vec) e tutti i vettori TF-IDF del dataset (tfidf).

cosine_similarity restituisce una matrice 1xN (N = numero documenti nel dataset), cioè la similarità tra la query e ogni documento.

La cosine similarity misura quanto sono simili questi vettori. Per esempio, due titoli con parole molto simili avranno un valore vicino a 1. Due titoli completamente diversi avranno un valore vicino a 0.

La cosine similarity è indipendente dalla lunghezza del documento, conta la direzione, non la dimensione, quindi è utile con dei testi, perché due testi di lunghezza diversa ma con parole simili, saranno considerati simili.

Successivamente troviamo i 5 indici dei valori più alti di similarità e selezioniamo dal dataset le righe corrispondenti agli indici trovati e stampiamo a video i Titoli con i rispettivi summary.

L'inserimento del titolo avviene grazie ad una search box interattiva. Il titolo da inserire deve contenere minimo 5 caratteri.

```
In [92]: def search(title):
    query_vec = vectorizer.transform([title])
    similarity = cosine_similarity(query_vec, tfidf).flatten()
    indices = np.argsort(similarity, -5)[-5:]
    results = data_set.iloc[indices].iloc[:, :-1]

    output = ""
    for _, row in results.iterrows():
        output += f"### {row['Title']}\n"
        output += f"{row['Summary']}\n\n"

    return Markdown(output)

news_input = widgets.Text(
    value='',
    description='Title:',
    disabled=False
)

def on_type(change):
    title = change["new"]
    if len(title) > 4:
        clear_output(wait=True)
        display(news_input)
        display(search(title))

news_input.observe(on_type, names='value')

display(news_input)
```

Text(value='prince', description='Title:')

The Brands Queen Elizabeth, Prince Charles, and Prince Philip Swear By

Shop the notebooks, jackets, and more that the royals can't live without.

Here's how Meghan Markle and Prince Harry's first family royal tour is different to Prince William and Kate Middleton's

Unlike Kate Middleton and Prince William, Harry and Meghan are individually touring different countries during their visit to Africa.

Prince George's Royal Life in Photos

Photos of the future king of England who is third in line for the throne, behind his father and Prince Charles.

What Do Prince George & Princess Charlotte Know About Their Royal Roles?

Do Prince William and Kate Middleton's kids know about their royal roles?

A Look Back at Prince Charles and Camilla's Relationship Through the Years

In honor of the third season of The Crown.

In []:

